

André de Moraes Yoshida, RA: 166241

Introdução a Aprendizado de Máquina (IA048)
Faculdade de Engenharia Elétrica e de Computação (FEEC)
Universidade Estadual de Campinas (Unicamp)
CEP 13083-852 – Campinas, SP, Brasil

{a166241}@dac.unicamp.br

Resumo – Dada a importância do conhecimento das vazões de rios futuras para o planejamento energético, neste projeto foram realizados previsões da série de vazões diárias no posto 18 Água Vermelha localizado na bacia do rio Grande, Brasil. Para isso, foi explorado modelos baseados em redes neurais recorrentes (RNN), utilizando como atributos do modelo dados de vazões passadas do posto. As previsões feitas foram de 7 dias à frente, utilizando duas metodologias de previsão de múltiplos passos a frente: o método direto, e o método recursivo. As previsões de ambas as metodologias apresentam um erro menor nos dois primeiros passos da série, porém, conforme o horizonte de previsão aumenta, o erro obtido também aumenta, além disso, como ambos os modelos apresentaram desempenhos semelhantes no processo de previsão, torna-se necessário a busca por novas metodologias ou outras abordagens a serem feitas nas previsões de múltiplos passos para poder melhorar o desempenho da rede.

Palavras chave – Redes recorrentes, Previsão de vazões, Previsão de múltiplos passos à frente, planejamento energético.

1. Introdução

Uma das principais variáveis dos modelos de otimização energética, que são utilizados pelo Operador Nacional do Sistema Elétrico(ONS) para a tomada de decisão no âmbito do Sistema Interligado Nacional(SIN), é a previsão de vazões afluentes futuras nos diversos postos presentes nos diversos rios e bacias do Brasil. Com isso, semanalmente são feitas simulações das vazões esperadas para a semana seguinte, que posteriormente são agregadas nos modelos de otimização e cuja informação é incorporada pelo ONS para a tomada de decisões.

O presente estudo apresenta um modelo de previsão semanal de vazões, discretizadas em escala diárias, utilizando redes neurais recorrentes(RNN).

2. Proposta

2.1 Dados




Figura 1: Vazões diárias da usina de Água Vermelha

A série de vazões diárias utilizada foi do posto 18, correspondente à usina de Água Vermelha, considerando o período de 10 anos(de 1 de janeiro de 2000 a 31 de dezembro de 2009). Além disso, utilizou-se o método de validação cruzada holdout para a separação dos dados, considerando para os dados de treinamento e validação: o período de 1 de janeiro de 2000 a 31 de dezembro de 2007, enquanto o período de 1 de janeiro de 2008 a 31 de dezembro de 2009 para a etapa de teste. De forma a melhorar o desempenho da rede, os dados foram normalizados utilizando a técnica de MinMaxScaler.

2.2 Modelo de Previsão

O modelo de rede neural recorrente LSTM(Long Short Term Memory), vem sendo utilizado [1] em diversas competições de modelos de previsão de séries, superando inclusive modelos já conhecidos como ARIMA e ETS. O modelo de rede LSTM possui internamente células de estados que representam tanto componentes de curto-prazo, quanto de longo prazo, que são capazes de captar padrões da série prevista.

Para o problema abordado, considerou-se que estrutura rede consiste em uma camada LSTM, em conjunto com uma camada densa com o número de neurônios igual a 1 no método recursivo, e 7 no método direto. O número de neurônios na camada LSTM, bem como seus hiperparâmetros foram obtidos através da técnica de GridSearch, e estão ilustrados na tabela abaixo:

	Método Direto	Método Recursivo
Batch_size	2	2
Épocas	30	30
Atrasos	25	25
Nº unidades LSTM	100	30

As função de ativação utilizada foi ReLu, com o algoritmo de otimização Adam.

2.2 Métodos de Múltiplas Saídas

Método recursivo: No método recursivo o modelo de rede neural é construído de forma a prever um passo a frente. Após a construção do modelo, para adaptar a saída para o caso de 7 passos à frente, utiliza o modelo da rede em cascata, acrescentado a saída de um passo no passo seguinte, conforme mostrado na figura abaixo obtida de [2].




Figura 2: Previsão recursiva de múltiplos passos

Método direto:

No método direto o modelo é construído de forma a prever os 7 passos à frente, sem necessitar de uma adaptação posterior. Desse modo, apenas precisamos ajustar os dados de entrada da rede, bem como os dados de saída para possuírem 7 neurônios, conforme mostrado no exemplo abaixo:

1 amostra:

Entrada	Saída
$[x_1 \quad x_2 \quad x_3 \quad \dots \quad x_n]$	$[x_{n+1} \quad x_{n+2} \quad x_{n+3} \quad \dots \quad x_{n+h}]$

2 amostra:

Entrada	Saída
$[x_2 \quad x_3 \quad x_4 \quad \dots \quad x_{n+1}]$	$[x_{n+2} \quad x_{n+3} \quad x_{n+4} \quad \dots \quad x_{n+h+1}]$

Onde h no nosso caso é igual a 7.

3. Resultados

Como forma de avaliar nossos resultados, utilizamos a função custo Root Mean Square Error (RMSE), cuja fórmula é mostrada abaixo:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Previsto_i - Atual_i)^2}$$

Assim, para validarmos nosso estudo, calculamos o RMSE total médio dos 7 dias previstos, bem como o RMSE por dia no nosso horizonte de previsão, para ambas as metodologias de múltiplos passos utilizados. A tabela abaixo mostrado os

valores obtidos sobre os dados de teste, em que [di] representa o valor do RMSE obtido para o dia i passos à frente:

RMSE(m ³ /s)	Total	d1	d2	d3	d4	d5	d6	d7
Método Direto	474	125	229	337	444	542	630	707
Método Recursivo	484	112	221	339	451	560	649	727
Diferença	-10	13	8	-2	-7	-18	-19	-20

Como pode ser observado, os valores obtidos para ambos os métodos são bem próximos, e inclusive apresentam um aumento percentual do erro RMSE ao longos dos 7 dias próximos. Também é possível observar que o modelo recursivo apresenta um menor erro para os primeiros dias do horizonte, enquanto o modelo direto possui melhor desempenho para os dias no final do horizonte,

4. Conclusões

Este trabalho propôs duas metodologias de previsão de múltiplos passos, utilizando para isso um modelo de rede neural recorrente LSTM, de forma a prever as vazões da semana seguinte, discretizadas em escala diária.

As duas metodologias analisadas apresentaram desempenhos próximos para essa tarefa, caracterizadas pela piora na previsão do modelo com o horizonte. Pretende-se em trabalhos futuros verificar o desempenho de modelos híbridos como o DirRec descrito em [2].

Além disso, pretende-se agregar a série com a média de 7 dias, reamostrando em frequência semanal, e com isso, convertendo o problema de previsão de vazão da semana seguinte, em um problema de previsão de um único passo.

Referências

- [1] Hewamalage, Hansika, Christoph Bergmeir, and Kasun Bandara. "Recurrent neural networks for time series forecasting: Current status and future directions." *arXiv preprint arXiv:1909.00590* (2019).
- [2] Taieb, Souhaib Ben, et al. "A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 forecasting competition." *Expert systems with applications* 39.8 (2012): 7067-7083.
- [3] Atiya, Amir & El-Shoura, Suzan & Shaheen, Samir & Mohamed, Soha. (1999). A Comparison Between Neural-Network Forecasting Techniques-Case Study: River Flow Forecasting., *Neural Networks, IEEE Transactions on*. 10. 402 - 409. 10.1109/72.750569.

